

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería de Transporte y Logística






Sistemas Urbanos Inteligentes

Redes Neuronales Recurrentes (RNN)

Hans Löbel


Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

Pensemos en un problema de predicción de velocidad en una red



¿Qué limitación tiene este enfoque?


Pasemos ahora a un problema de estimación de modo




¿Qué limitación tiene este enfoque?

Afortunadamente, existen redes llamadas **Redes Neuronales Recurrentes** (RNN), que están hechas para procesar secuencias


- Propuestas en la década de los 80.
- Trabajan de manera secuencial, procesando uno a uno los elementos de la secuencia/serie.
- A diferencia de métodos tradicionales y de otros tipos de redes, las RNN mantienen un estado, es decir, “tienen memoria”.
- Cómo se maneja esta memoria es lo que caracteriza a los distintos tipos de redes recurrentes existentes (RNN, LSTM, GRU).



Expandamos este diagrama, para ver explícitamente el funcionamiento de una RNN en el tiempo




Expandamos este diagrama, para ver explícitamente el funcionamiento de una RNN en el tiempo




$$h_t = \sigma(f_1(x_t), f_2(h_{t-1}))$$

Formalicemos un poco esto




- x_t : vector de entrada que codifica la secuencia en el paso t
- h_t : vector de estado oculto (latente/interno) en el paso t , que codifica la **historia** de la entrada hasta ese momento
- f_1 y f_2 : funciones paramétricas **entrenables** (aquí está la clave)
- t : paso de la secuencia, usualmente tiene significado temporal, pero puede representar cualquier relación de orden (espacio, ranking, etc).

La configuración típica de una RNN es con funciones lineales y sigmoides



$$h_t = \sigma(W_{hh} h_{t-1} + W_{xh} x_t)$$


La configuración típica de una RNN es con funciones lineales y sigmoides



$$h_t = \sigma(W_{hh} h_{t-1} + W_{xh} x_t)$$

- Al ver esto en detalle, podemos inferir que se genera un grafo de cómputo profundo, sin un incremento en la cantidad de parámetros (¿por qué?).
- Esto implica que al utilizar una capa recurrente, podemos capturar dependencias de longitud arbitraria en los datos, controlando efectivamente la capacidad del modelo (no necesitamos filtros más grandes).


Las redes recurrentes como elementos de memoria



$$h_t = \sigma(W_{hh} h_{t-1} + W_{xh} x_t)$$

- Las RNN **aprenden** a usar el estado oculto h_t como una **feature** que representa las entradas hasta el paso t , es decir, captura solo la información relevante para la tarea.
- Esto permite capturar la estructura secuencial/temporal de la entrada (análogamente a como las convoluciones capturan la estructura espacial en una CNN).

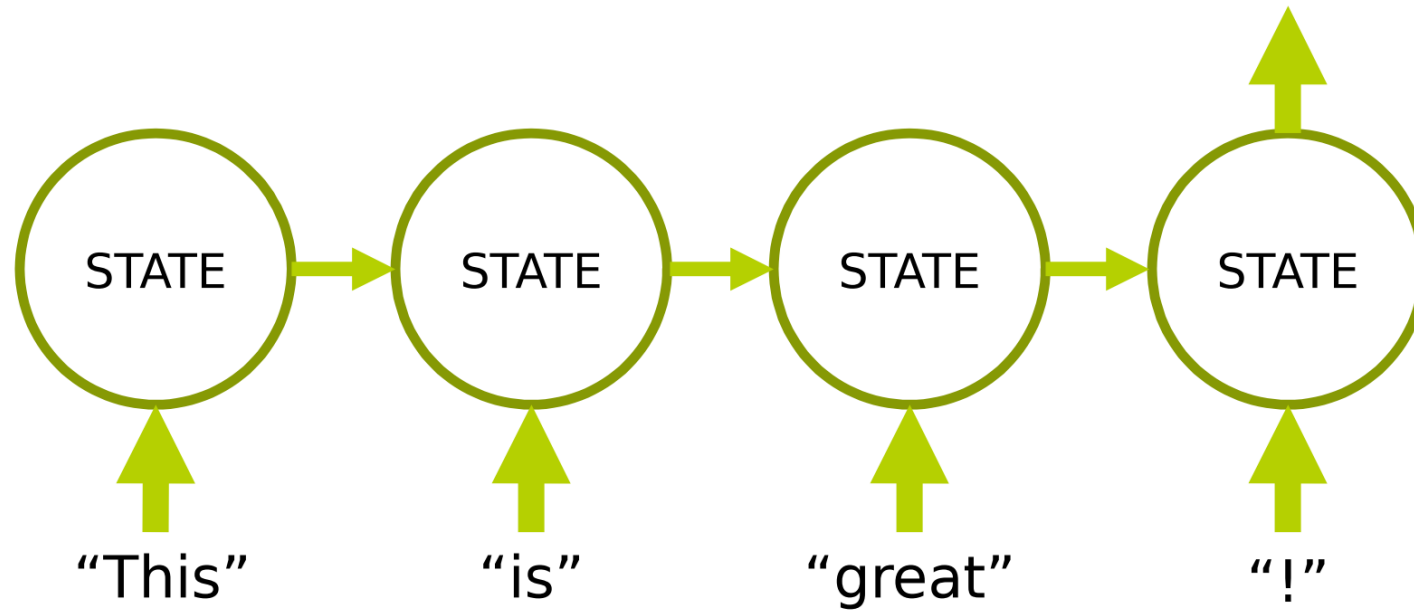
Aún nos falta generar la salida que nos permita utilizar supervisión para el aprendizaje



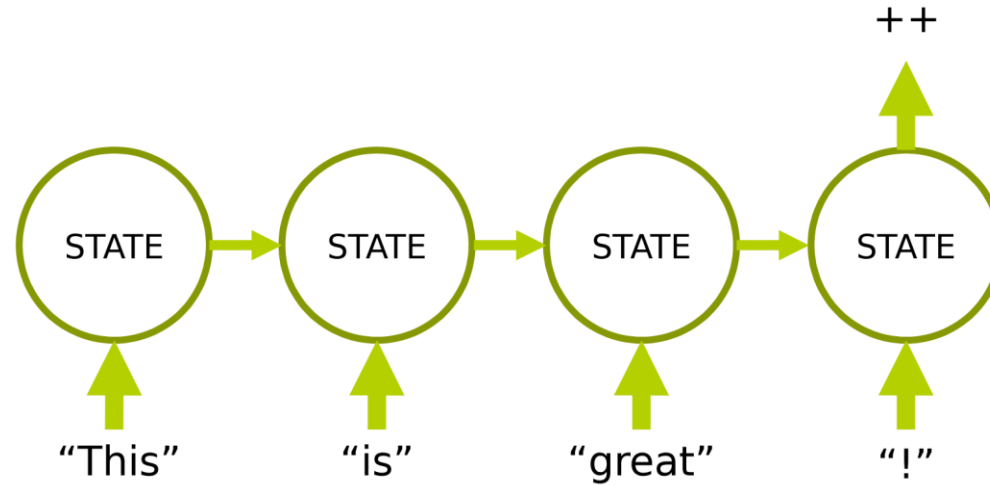
$$h_t = \sigma(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$y = \sigma(W_{hy} h_T)$$

Veamos un caso aplicado: predicción de sentimiento

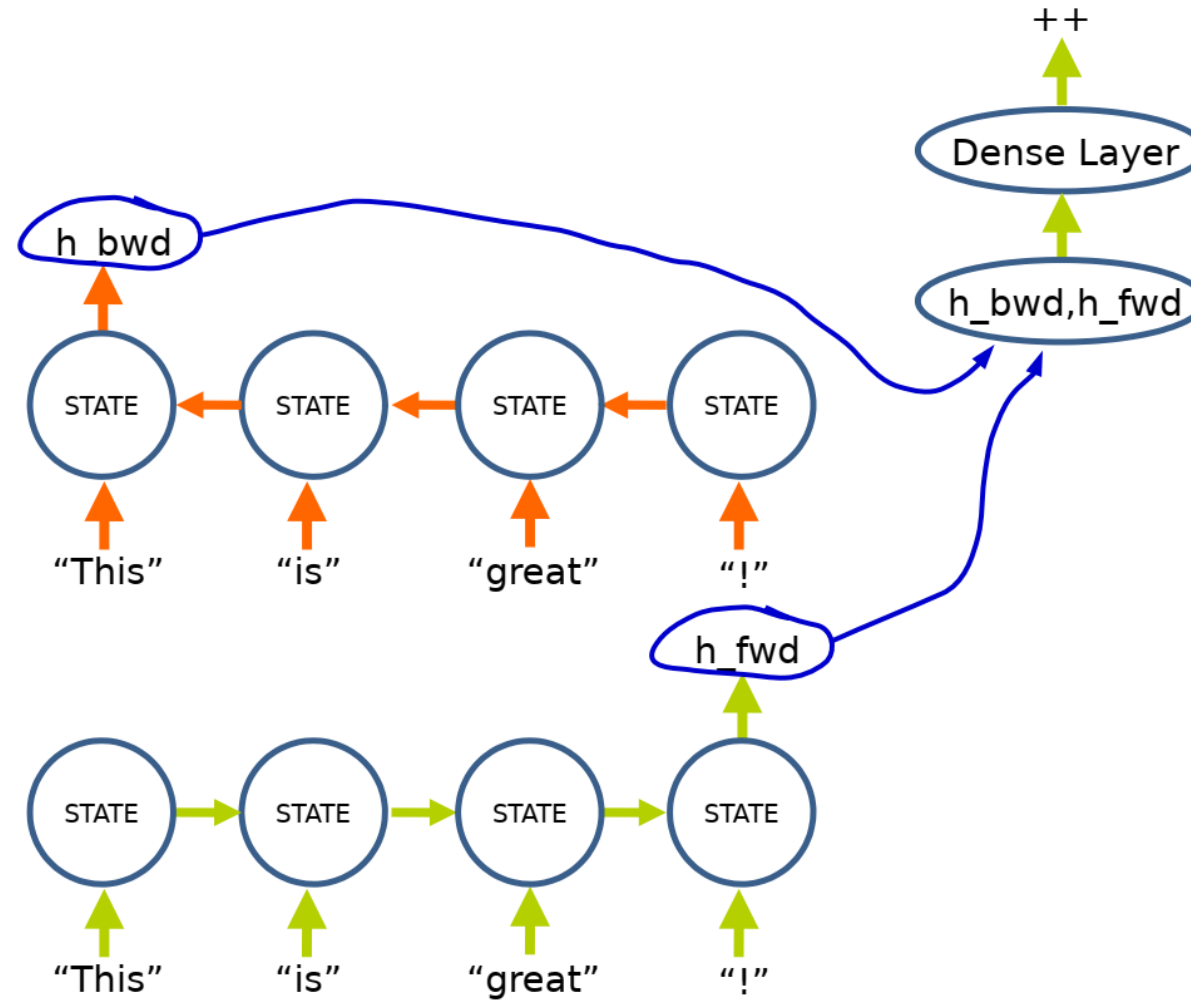


Veamos un caso aplicado: predicción de sentimiento




- En cada paso, el estado oculto modela la historia/características de la secuencia hasta el momento.
- En **este problema particular**, podemos también capturar la información que viene a continuación, mediante una **RNN bidireccional**.

Veamos un caso aplicado: predicción de sentimiento con una RNN bidireccional




La salida de una RNN puede adecuarse a la tarea de turno

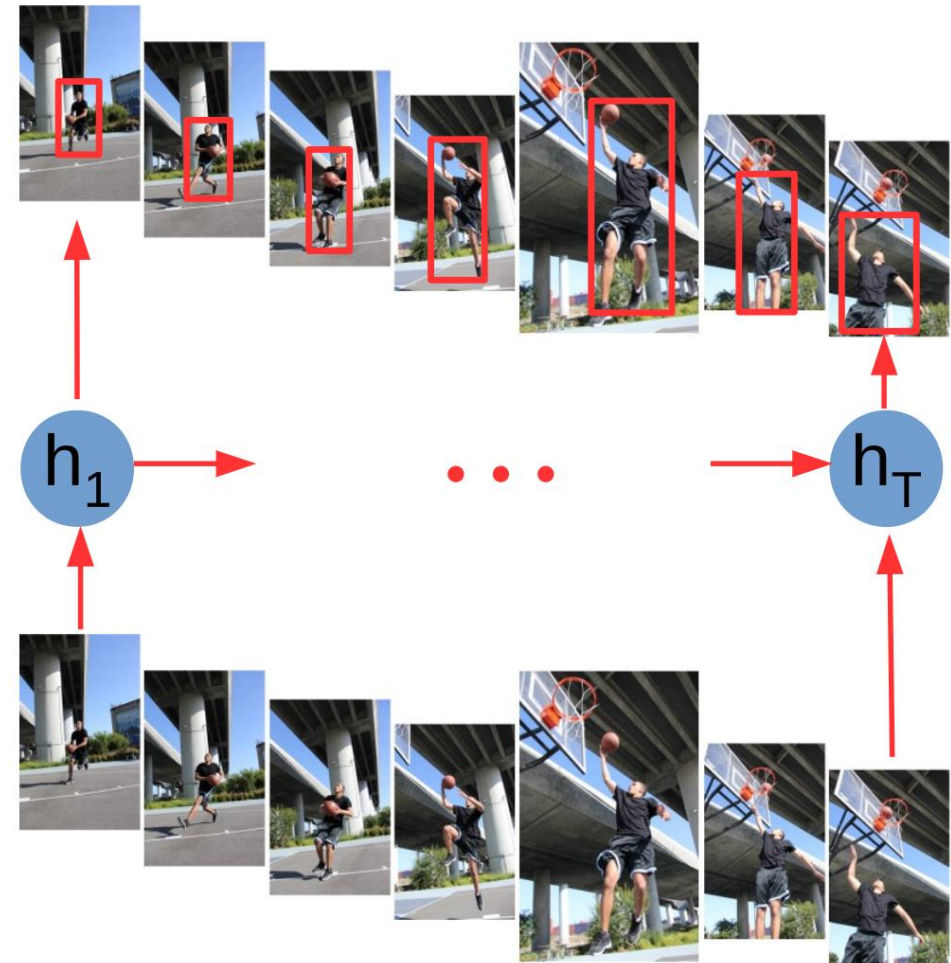



En esta configuración, la RNN genera una salida por cada valor de la secuencia de entrada.

La salida de una RNN puede adecuarse a la tarea de turno



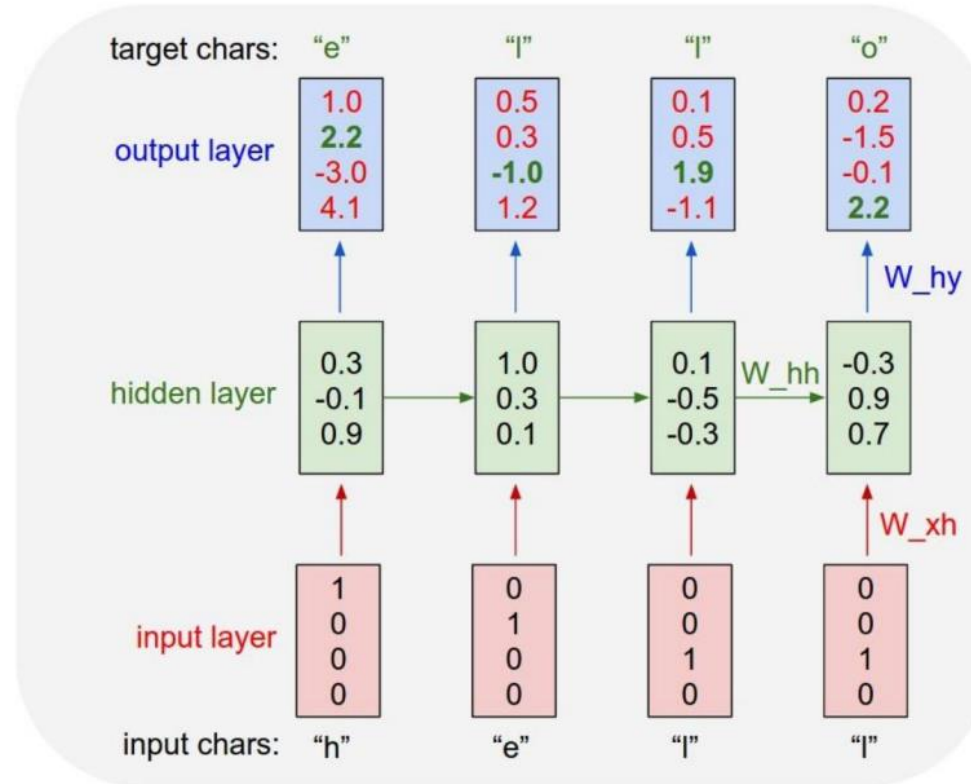
Veamos más ejemplos: seguimiento en videos



Veamos más ejemplos: generación de texto a nivel de caracteres

Vocabulary:
[h,e,l,o]

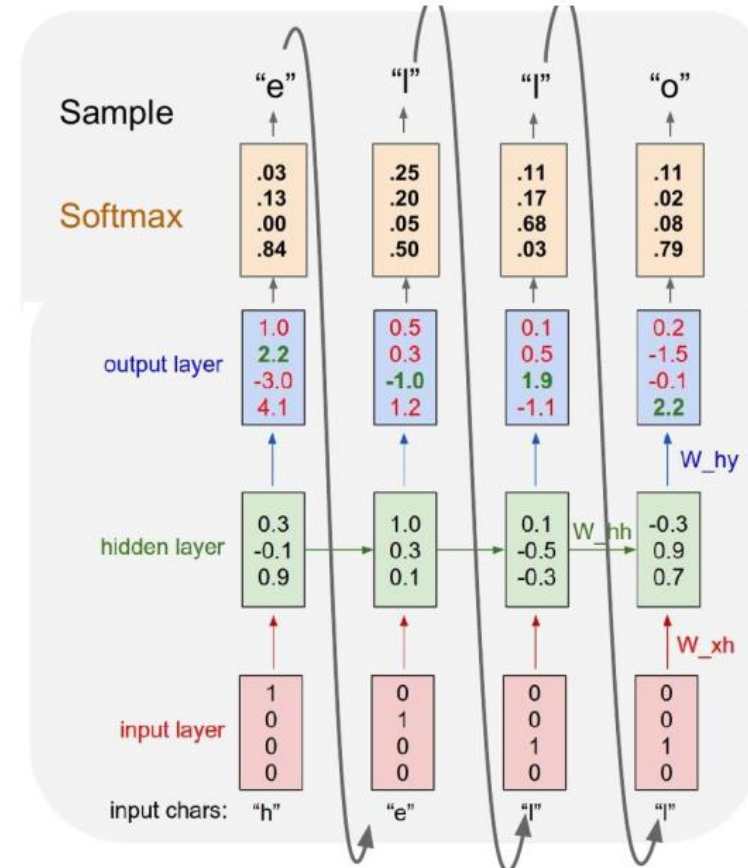
Example training
sequence:
“hello”



Veamos más ejemplos: generación de texto a nivel de caracteres

Vocabulary:
[h,e,l,o]

At test-time sample
characters one at a time,
feed back to model




Veamos más ejemplos: generación de texto a nivel de caracteres

THE SONNETS

by William Shakespeare

From fairest creatures we desire increase,
That thereby beauty's rose might never die,
But as the ripper should by time decease,
His tender heir might bear his memory:
But thou, contracted to thine own bright eyes,
Feed'st thy light's flame with self-substantial fuel,
Making a famine where abundance lies,
Thyself thy foe, to thy sweet self too cruel:
Thou that art now the world's fresh ornament,
And only herald to the gaudy spring,
Within thine own bud buriest thy content,
And tender churl mak'st waste in niggarding:
 Pity the world, or else this glutton be,
 To eat the world's due, by the grave and thee.

When forty winters shall besiege thy brow,
And dig deep trenches in thy beauty's field,
Thy youth's proud livery so gazed on now,
Will be a tatter'd weed of small worth held:
Then being asked, where all thy beauty lies,
Where all the treasure of thy lusty days;
To say, within thine own deep sunken eyes,
Were an all-eating shame, and thriftless praise.
How much more praise deserv'd thy beauty's use,
If thou couldst answer 'This fair child of mine
Shall sum my count, and make my old excuse,'
Proving his beauty by succession thine!
 This were to be new made when thou art old,
 And see thy blood warm when thou feel'st it cold.



Veamos más ejemplos: generación de texto a nivel de caracteres

tyntd-iafhatawiaoihrdemot lytdws e ,tfti, astai f ogoh eoase rrranbyne 'nhthnee e
plia tklrqd t o idoe ns,smtt h ne etie h,hregtrs nigtike,aoaenns lng



train more

"Tmont thithey" fomesscerliund
Keushey. Thom here
sheulke, anmerenith ol sivh I lalterthend Bleipile shuw y fil on aseterlome
coaniogennc Phe lism thond hon at. MeiDimorotion in ther thize."



train more


Aftair fall unsuch that the hall for Prince Velzonski's that me of
her hearly, and behs to so arwage fiving were to it beloge, pavu say falling misfort
how, and Gogition is so overelical and ofter.



train more

"Why do what that day," replied Natasha, and wishing to himself the fact the
princess, Princess Mary was easier, fed in had oftended him.
Pierre aking his soul came to the packs and drove up his father-in-law women.


Si bien las RNN pueden tener diversas configuraciones, la clave es **compartir pesos** de manera **profunda** al incluir **ciclos**



$$h_t = f(h_{t-1}, x_t)$$

Los ciclos, o conexiones recurrentes, son la herramienta que provee cierto grado de memoria. La profundidad de esta recurrencia define cuán “grande” es la memoria.

Si bien las RNN pueden tener diversas configuraciones, la clave es **compartir pesos** de manera **profunda** al incluir **ciclos**



$$h_t = f(h_{t-1}, x_t)$$

- El compartir parámetros provee un mecanismo para modelar secuencias de largos arbitrarios.
- Al verlo en detalle, podemos notar que al desenrollar el procesamiento de una secuencia con una RNN, esta se transforma en algo parecido a un MLP donde todas las capas comparten los parámetros.
- A diferencia de la estructura fija para compartir parámetros de las CNN (filtro convolucional), las RNN permiten que este acto sea profundo (estado oculto actualizado de acuerdo al largo de la secuencia).

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ingeniería de Transporte y Logística



Sistemas Urbanos Inteligentes

Redes Neuronales Recurrentes (RNN)

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación